

Optimasi Akurasi Pemodelan Prediksi Harga Beras Medium Kota Mojokerto dengan LSTM

Dinarta Hanum¹, Joko Ristono²

Informatika, Fakultas Ekonomi Bisnis dan Digital, Universitas Bina Sehat PPNI Mojokerto, Indonesia

dinartahanum@gmail.com¹

Kata Kunci:

Inflasi, Beras
Medium,
Siskaperbapo, LSTM,
Akurasi.

Abstrak

Salah satu pilar untuk mewujudkan ketahanan pangan di Indonesia adalah pilar aksesibilitas yang mana merupakan kemampuan rumah tangga memperoleh cukup pangan yang salah satunya berasal dari pembelian. Sedangkan komoditas pangan di Indonesia yang sering mengalami naik turunnya harga adalah komoditas beras. Penyebab naik turunnya harga beras adalah berkurangnya intensitas produksi beras karena iklim dan cuaca yang tidak menentu sehingga membuat gagal panen. Hal tersebut memicu kenaikan harga pangan beras di pasaran. Kenaikan harga beras jika tidak segera diatasi dapat mengakibatkan Inflasi. Pada dasarnya, pemerintah telah berupaya mengendalikan inflasi dan berfokus pada komoditas beras yang menjadi penyumbang utama peningkatan inflasi. Pemodelan prediksi harga beras dengan *Long Short Term Memory* (LSTM) dapat menjadi hadirnya teknologi prediksi yang sangat diperlukan dalam menghindari Indonesia dari kenaikan harga beras pada waktu tertentu dan dapat digunakan sebagai rujukan pemerintah dalam mengambil kebijakan. Penelitian ini bertujuan untuk melakukan optimasi akurasi pemodelan prediksi harga beras medium dengan metode LSTM. Data yang digunakan adalah data harga beras medium dari tahun 2021 sampai dengan 2024 yang diperoleh dari Sistem Informasi Ketersediaan dan Perkembangan Harga Bahan Pokok (Siskaperbapo) Jawa Timur. Analisis data menggunakan metode LSTM dengan tujuh jenis optimasi untuk mendapatkan nilai akurasi terbaik. Dari tujuh jenis optimasi yang menghasilkan nilai akurasi terbaik adalah optimasi Adam dengan struktur LSTM nilai *epoch* 99 dan ukuran *batch* 30.

Key Word:

Inflation, Medium
Rice, Siskaperbapo,
LSTM, Accuracy.

Abstract

One of the pillars for realizing food security in Indonesia is the accessibility pillar, which is the ability of households to obtain sufficient food, one of which comes from purchases. Meanwhile, the food commodity in Indonesia that often experiences price fluctuations is rice. The cause of the increase in rice prices is the reduced intensity of rice production due to uncertain climate and weather, resulting in crop failures. This triggers an increase in the price of rice on the market. The increase in rice prices if not addressed immediately can result in inflation. Basically, the government has tried to control inflation and focus on rice commodities which are the main contributors to the increase in inflation. Modeling rice price predictions with *Long Short Term Memory* (LSTM) can be the presence of prediction technology that is very much needed in preventing Indonesia from increasing rice prices at certain times and can be used as a reference for the government in making policies. This study aims to optimize the accuracy of medium rice price prediction modeling using the LSTM method. The data used is medium rice price data from 2021 to 2024 obtained from the East Java Staple Food Availability and Price Development Information System (Siskaperbapo). Data analysis using the LSTM method with seven types of optimization to obtain the best accuracy value. Of the seven types of optimization that produces the best accuracy value is Adam optimization with an LSTM structure, epoch value 99 and batch size 30.

Copyright © 2024 Dinarta Hanum, Joko Ristono

This work is licensed under an **Attribution-ShareAlike 4.0 International (CC BY-SA 4.0)**

PENDAHULUAN

Manusia memiliki kebutuhan dasar akan makanan yang harus selalu dipenuhi. Akses terhadap pangan merupakan hak asasi manusia yang mendasar, mengingat signifikansi dan fungsinya dalam negara. Ketika suatu negara mengalami kondisi kebutuhan pangan lebih tinggi dari ketersediaan pangan dapat menciptakan ketidakstabilan ekonomi. Ketidakstabilan ekonomi merupakan kondisi dimana negara mengalami guncangan terhadap cara ekonomi yang pada umumnya berakibat pada ketidakstabilan sosial dan juga politik. Stabilitas politik dan ekonomi dapat terancam oleh kondisi pangan yang tidak stabil. Beras adalah makanan pokok, oleh karena itu makanan dan beras berjalan beriringan. Upaya pemerintah dalam meningkatkan ketahanan pangan bagi masyarakat, dari segi produksi dalam negeri maupun tambahan produksi dari impor dinilai sebagai tindakan pemerintah yang tepat (Fauzin, 2021).

Sampai saat ini, beras adalah bahan makanan yang paling signifikan meningkatkan inflasi. Secara umum, Pemerintah telah menerapkan sejumlah kebijakan dan taktik untuk mencoba membatasi laju kenaikan harga pangan di pasar, terutama untuk barang-barang pokok dan penting seperti beras. Kesejahteraan masyarakat dan petani akan terdampak oleh perubahan harga beras karena beras merupakan komoditas yang memiliki dampak ekonomi dan sosial yang signifikan. Pada tahun 2024, harga beras premium dan medium akan terus meningkat, seperti yang dirasakan oleh masyarakat Indonesia. Harga beras yang naik dapat menimbulkan kekhawatiran serius, terutama bagi kelompok masyarakat menengah ke bawah, terkait dengan kebutuhan dan ketersediaan pangan. Salah satu faktor yang menyebabkan kenaikan harga beras di tahun 2024 adalah penurunan produksi akibat dampak perubahan iklim ekstrem yang melanda Indonesia sejak pertengahan tahun 2023, yang akhirnya menyebabkan gagal panen. Gagal panen menyebabkan krisis produksi beras, yang berdampak pada kelangkaan dan mendorong kenaikan harga beras di pasaran. Pada tahun 2024, harga beras medium sempat mencapai dua puluh ribu rupiah per kilogram.

Pada tahun 2021, 2022, dan 2023, dalam berbagai situasi, terlihat bahwa beras juga mengalami variasi. Pemerintah menetapkan undang-undang untuk memastikan sistem perdagangan beras yang adil dengan menentukan harga eceran tertinggi untuk kelas medium/premium. Akan tetapi, fluktuasi diciptakan oleh sistem perdagangan beras, yang memiliki pengaruh besar pada harga beras. Tujuan dari Permentan Nomor 31 Tahun 2017 tentang kelas kualitas beras adalah untuk melindungi hak-hak konsumen dan menjadi dasar untuk memantau kualitas dan harga beras, yang menghasilkan pembagian beras ke dalam dua kelas kualitas: premium dan medium. Sehingga penyebab harga beras medium mengalami fluktuasi tidak selalu karena produksi beras yang langka namun juga disebabkan tata niaga beras yang berkeadilan.

Kehadiran teknologi pemodelan prediksi harga beras kualitas medium/premium sangat penting untuk mencegah lonjakan harga pada waktu tertentu akibat masalah tata niaga. Teknologi ini juga dapat membantu pemerintah dalam mengambil keputusan kebijakan yang tepat. Penelitian sebelumnya tentang pengaruh fluktuasi harga komoditas pangan terhadap inflasi di provinsi Jawa Timur menggunakan metode VAR-VECM menerangkan bahwa dalam jangka pendek fluktuasi harga beras mentik berpengaruh negatif terhadap inflasi sedangkan dalam jangka panjang fluktuasi harga beras mentik berpengaruh positif terhadap inflasi (Kusnadi, 2018). Penelitian juga dilakukan tentang fluktuasi harga komoditas pangan dan pengaruhnya terhadap inflasi di Sumatera Barat dengan metode VAR-VECM yang menerangkan bahwa komoditas pangan beras mengalami fluktuasi setiap bulannya dan pada jangka pendek harga beras berpengaruh signifikan terhadap inflasi (Hariyanti *et al.*, 2023). Sedangkan pengertian inflasi adalah suatu kecenderungan meningkatnya harga-harga barang dan jasa secara umum dan terus menerus (Suseno & Siti Astiyah, 2009).

Ada banyak cara untuk memprediksi harga beras. Salah satu penelitian tentang penggunaan teknik regresi linier dasar untuk memprediksi harga beras di kota Malang menjelaskan bahwa penggunaan teknik regresi linier untuk memprediksi harga beras dapat dikatakan dalam kategori sangat baik karena root mean square error (RMSE) yang sangat kecil (Hasibuan *et al.*, 2022). Sedangkan untuk penelitian ini dalam melakukan pemodelan prediksi harga beras medium Kota Mojokerto menggunakan metode Long Short Term Memory (LSTM). Pertimbangan penulis memilih metode LSTM karena setelah studi literatur membandingkan kinerja algoritma LSTM dan regresi linear. Penelitian mengenai perbandingan algoritma regresi linear dan Long Short Term Memory dalam memprediksi harga saham dengan model *time series* menerangkan bahwa dengan dataset dapat memberikan performa yang terbaik dari algoritma regresi linear dan LSTM. Setelah dilakukan proses *preprocessing data*, hasilnya menunjukkan bahwa algoritma *Long Short Term Memory* lebih unggul karena memiliki kinerja yang lebih baik dari regresi linear. Kedua algoritma juga menggunakan *Root Mean Square Error* (RMSE) sebagai pengukuran parameter. Nilai RMSE yang dihasilkan oleh algoritma regresi linear lebih tinggi dibandingkan nilai RMSE dari algoritma LSTM (Sofi, *et al.*, 2021). Penelitian terdahulu tentang analisis data *time series* menggunakan *Long Short Term Memory* (LSTM) dan ARIMA dalam Bahasa Python menerangkan bahwa prediksi data *time series* dengan LSTM lebih akurat dibandingkan dengan ARIMA (Karno, 2020).

Jaringan syaraf tiruan (JST) sederhana, yang hanya memiliki tiga komponen - input, model jaringan, dan output - dan terbatas untuk digunakan dengan metode regresi linier, adalah sumber dari LSTM. Kemudian selanjutnya berkembang menjadi model *one to many* dimana output dari proses sebelumnya akan digunakan sebagai input selanjutnya dari proses yang sama (Pant, 2017). LSTM merupakan jaringan yang dibangun secara khusus dalam menangani permasalahan jangka panjang dan tidak bergantung dengan pengaruh jangka panjang sehingga sesuai untuk melakukan prediksi deret waktu. LSTM juga sesuai digunakan untuk memproses, melakukan peramalan dan mengklasifikasi data deret waktu karena ada kemungkinan durasi yang tidak dapat diketahui diantara kejadian dalam data tersebut yang penting dalam rangkaian tertentu (Aldi *et al.*, 2018). Penelitian pengujian algoritma LSTM untuk prediksi kualitas udara dan suhu Kota Bandung menerangkan

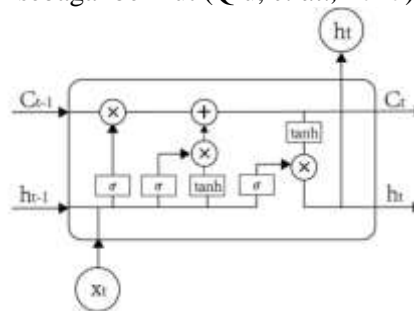
bahwa hasil pemodelan LSTM menunjukkan bahwa jaringan memiliki kinerja yang cukup baik pada prediksi *training* dan *testing* (Khumaidi, *et al.*, 2020). Dalam penelitian ini dilakukan optimasi akurasi pemodelan prediksi harga beras medium di Kota Mojokerto menggunakan optimasi Adam, Nadam, SGD, Adadelta, Adagrad, Adamax dan FTRL.

Teknik algoritme optimasi berbasis gradien stokastik yang disebut optimasi Adaptive Moment Estimation (Adam) dapat diterapkan secara langsung pada model dengan kumpulan data dan parameter yang besar, sehingga dapat meningkatkan akurasi. Stochastic Gradient Descent (SGD) dengan momentum dan RMSprop digabungkan dalam optimasi Adaptive Moment Estimation (Adam). Adam menggunakan momentum rata-rata bergerak gradien seperti SGD dengan momentum dan gradien kuadrat untuk mengukur tingkat pembelajaran yang mirip dengan RMSprop. Adam merupakan metode learning rate adaptif dimana penghitungan learning rate untuk individu memiliki parameter yang berbeda sedangkan optimasi nadam adalah algoritma adam dengan menggabungkan momentum nesterov pada gradient descent (Kingma, *et al.*, 2015). Optimasi model prediksi sangat bervariasi oleh karena itu perlu dicari literasi yang membandingkan kinerja optimizer. Seperti pada penelitian analisa perbandingan performa optimizer Adam, SGD, dan RMSPROP pada model H5 yang menerangkan bahwa optimizer adam memiliki akurasi terbaik kemudian disusul SGD dan RMSPROP (Anggara, *et al.*, 2023). Sedangkan penelitian implementasi metode LSTM untuk memprediksi harga bahan pokok nasional menerangkan bahwa optimizer RMSProp menghasilkan model terbaik dengan RMSE terkecil (Cahyani, *et al.*, 2023).

Dengan dasar penelitian sebelumnya maka penelitian ini dalam melakukan pemodelan prediksi harga beras medium Kota Mojokerto menggunakan metode LSTM dan menguji kebaikan modelnya dengan RMSE untuk memperoleh akurasi terbaik. Optimasi akurasi ini dilakukan untuk memperoleh model terbaik dalam prediksi harga beras medium. Dalam metode LSTM, perlu ditetapkan ukuran *batch* dan nilai *epoch* karena besarnya *batch* akan berdampak pada hasil *deep learning* (Rochamawati, *et al.*, 2021). Pemodelan prediksi harga beras medium dengan akurasi terbaik dapat digunakan pemerintah dalam mengambil kebijakan agar dapat mewujudkan tata niaga beras yang berkeadilan.

METODE

Jaringan yang dirancang dengan mempertimbangkan isu jangka panjang disebut Long Short Term Memory (LSTM). Salah satu jenis RNN yang paling populer, Long Short Term Memory (LSTM), digunakan untuk memproses dan memprediksi deret waktu sambil menghindari isu ketergantungan jangka panjang. Struktur sel memori LSTM digambarkan sebagai berikut (Qiu, *et al.*, 2020):



Gambar 1. Struktur LSTM

Angka antara nol dan satu, yang mewakili jumlah setiap komponen yang harus dilewatkan. Jika data berada dalam rentang $0 \leq \sigma \leq 0,5$, sigmoid akan menjadi nol; jika berada dalam rentang $0,5 < \sigma \leq 1$. Algoritma yang digunakan dalam LSTM adalah sebagai berikut:

Menentukan nilai sigmoid dan tanh dengan rumus:

$$\sigma(x) = \frac{1}{1 + e^{-x}}$$
$$\tanh \tanh(x) = 2\sigma(2x) - 1$$

dengan x adalah data input dan e adalah konstanta matematika.

Mengubah data yang akan digunakan menjadi dataset;

Menggunakan min-max scaler untuk normalisasi;

Membagi dataset menjadi data training dan testing;

Menghitung banyaknya hidden layer, neuron dan epoch yang akan digunakan dalam pembuatan model LSTM.

Metode LSTM dalam penelitian ini meliputi 3 (tiga) tahapan yaitu tahapan *preprocessing*, pembangunan model LSTM dan evaluasi model.

Preprocessing Data

Peneliti menggunakan harga harian beras kualitas medium di Kota Mojokerto dari tahun 2021 hingga 2024, yang diperoleh dari Sistem Informasi Ketersediaan dan Perkembangan Harga Pangan Pokok Jawa Timur, (<https://siskaperbapo.jatimprov.go.id>).

Data harian harga beras medium dalam satu file csv yang kemudian diimpor ke dalam aplikasi *Google Colab*. Data yang telah diimpor ke aplikasi kemudian diubah menjadi dataset baru selanjutnya dilakukan tahap *preprocessing*.

[illegible]

Gambar 2. Tampilan 10 Baris Dataset Harga Beras Kualitas Medium

Tahap *preprocessing* meliputi proses pembagian *training* dan *testing data*. *Training data* adalah bagian dataset yang dilatih untuk membuat prediksi sedangkan data *testing* adalah bagian dataset yang dites untuk melihat akurasi. Dalam penelitian ini ada sejumlah 1.113 data dan dibagi *training:testing* (65:35). Sehingga 724 data sebagai data *training* yang akan dilatih untuk membuat prediksi dan 389 data sebagai data *testing* yang akan dites untuk melihat akurasi. Data *training* yang telah terbentuk kemudian dilakukan normalisasi menggunakan fungsi `MinMaxScaler`.

```
scaler = MinMaxScaler(feature_range=(0,1))
scaled_data = scaler.fit_transform(dataset)
np.set_printoptions(threshold=np.inf)
print(scaled_data)
```

Gambar 3. Kode Pemanggilan MinMax Scaler

Normalisasi data diperlukan selama proses pembelajaran mesin karena telah terbukti meningkatkan akurasi dan kelayakan model.

```
print(scaled_data)
```

```
[0.75  ]
[0.75  ]
[0.75  ]
[0.75  ]
[0.75  ]
[0.75  ]
[0.75  ]
[0.75  ]
[0.75  ]
[0.75  ]
```

Gambar 4. Tampilan Data Setelah Proses Normalisasi

Pembangunan Model

Pembangunan model LSTM menggunakan produk *Google Research*, yang juga disebut sebagai Google Colab. Kode yang digunakan untuk membangun model di *interface google colab* adalah sebagai berikut:

```
import math
import pandas_datareader as web
import numpy as np
import pandas as pd
from sklearn.preprocessing import MinMaxScaler
from keras.models import Sequential
from keras.layers import Dense, LSTM
import matplotlib.pyplot as plt
from datetime import datetime
```

Gambar 5. Kode LSTM pada google colab

Evaluasi Model

Melakukan evaluasi terhadap hasil pemodelan prediksi harga beras medium Kota Mojokerto untuk meningkatkan kelayakan model yang telah dibangun. Dalam penelitian ini menggunakan 7 (tujuh) variasi optimasi LSTM yaitu optimasi Adam, Nadam, Adamax, Adadelata, Adagrad, SGD dan FTRL.

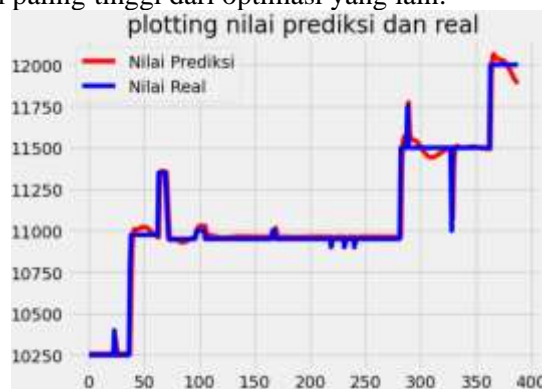
HASIL DAN PEMBAHASAN

Setelah menyelesaikan tahap normalisasi, yang melibatkan pemisahan data pelatihan (65%) dan data pengujian (35%), langkah selanjutnya melibatkan pengujian parameter, yang dilakukan melalui trial and error. Proses memperoleh nilai parameter model dikenal sebagai tuning parameter. Kombinasi parameter yang optimal dengan nilai epoch 99 dan batch size 30 ditemukan melalui pengujian parameter untuk data harga beras kualitas medium Kota Mojokerto dengan menggunakan metode Long Short Term Memory dan optimizer Nadam, Adam, SGD, Adagrad, Adamax, Adadelata, dan FTRL.

Tabel 1. Hasil Uji Variasi Optimasi

Jenis Optimasi LSTM	Nilai RMSE	
	Epoch	
	99	100
	batch = 30	
Adam	2,347636166	16,62423934
Nadam	20,66285748	163,3852527
SGD	141,1620365	174,9992318
Adagrad	165,4851080	164,3389927
Adamax	144,7969603	166,4339879
Adadelata	648,3248262	545,7382386
FTRL	1555,240897	1554,968436

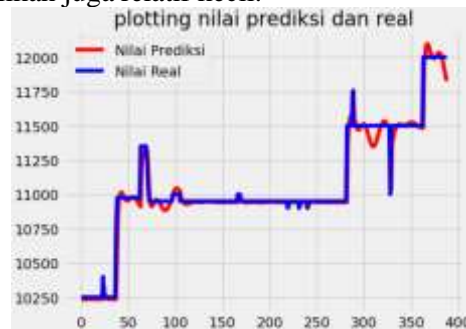
Tabel 1 menunjukkan bahwa teknik optimasi Adam memiliki akurasi tertinggi dengan nilai RMSE sebesar 2,347636166. Optimasi Nadam, Adamax, SGD, Adagrad, dan Adadelata mengikuti urutan RMSE yang menurun. Optimasi FTRL menghasilkan akurasi terendah. Selanjutnya penjelasan lebih rinci tentang hasil pemodelan prediksi harga beras kualitas medium dengan optimasi Adam, Nadam, SGD, Adamax, Adadelata, Adagrad dan FTRL, *epoch* = 99, *epoch* = 100 dan *batch* = 30 untuk memperkuat bukti bahwa akurasi yang diperoleh dengan optimasi Adam paling tinggi dari optimasi yang lain.



Gambar 6. Plotting Nilai Prediksi dan Nilai nyata Dengan Optimasi Adam, *epoch* = 99, *batch* = 30

Plotting pada gambar 6 dengan optimasi adam, *epoch* = 99 dan *batch* = 30, grafik data *testing* (aktual) menggunakan plot warna biru, sedangkan warna merah merupakan data prediksi. Hubungan antara kedua plot data menunjukkan bahwa, dari data 1 hingga 350, prediksi LSTM dapat secara akurat dan optimal mengestimasi nilai harga beras kualitas menengah. Namun, overfitting mulai muncul pada data ke-350 ke depan, yang menurunkan tingkat akurasi. Kondisi yang digambarkan melalui plotting pada gambar 6 antara

$epoch = 99$ dan $epoch = 100$ tidak berbeda signifikan. Tampak hasil plotting dengan optimasi adam, $epoch = 99$ dan ukuran $batch = 30$ memiliki gap yang sangat kecil atau dapat dikatakan bahwa hasil pemodelan prediksi menggunakan model *Long Short Term Memory* mendekati data asli atau aktual. Hal tersebut juga diperkuat dengan nilai akurasi RMSE yang lebih kecil dari 5 persen. Hasil plotting dengan optimasi adam dianggap paling akurat dibandingkan optimasi yang lain. RMSE yang diperoleh dengan optimasi Adam sangat optimal sehingga nilai kesalahan yang dihasilkan juga relatif kecil.



Gambar 7. Plotting Nilai Prediksi dan Nilai nyata Dengan Optimasi Adam, $epoch = 100$, $batch = 30$

Sedangkan plotting pada gambar 7 dengan optimasi adam, $epoch = 100$ dan $batch = 30$, grafik data *testing* (aktual) menggunakan plot warna biru, sedangkan warna merah merupakan data prediksi. Hubungan antara kedua plot data menunjukkan bahwa, dari data 1 hingga 350, prediksi LSTM dapat secara akurat dan optimal mengestimasi nilai harga beras kualitas menengah. Namun, overfitting mulai muncul pada data ke-350 ke depan, yang menurunkan tingkat akurasi. Tampak hasil plotting dengan optimasi adam, $epoch = 100$ dan ukuran $batch = 30$ memiliki gap yang kecil atau dapat dikatakan bahwa hasil prediksi menggunakan model *Long Short Term Memory* mendekati data asli atau aktual. Hal tersebut juga diperkuat dengan nilai akurasi RMSE yang lebih kecil dari 20 persen.



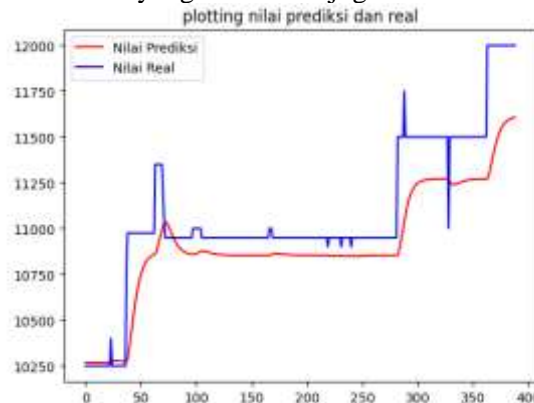
Gambar 8. Plotting Nilai Prediksi dan Nilai nyata Dengan Optimasi Nadam, $epoch = 99$, $batch = 30$

Pada gambar 8 mengilustrasikan kesenjangan yang cukup signifikan antara data hasil prediksi dengan data pengujian aktual, yang mengindikasikan bahwa hasil prediksi menggunakan model *Long Short Term Memory* (LSTM) dengan optimasi Nadam tidak sesuai dengan data aktual. Pengamatan ini didukung lebih lanjut oleh nilai akurasi RMSE yang melebihi 20 persen, sehingga dapat disimpulkan bahwa berdasarkan kriteria nilai RMSE, model LSTM dengan optimasi Nadam termasuk dalam kriteria performa yang tidak akurat. Hasil plotting dengan optimasi Nadam dianggap kurang akurat dibandingkan optimasi Adam. RMSE yang diperoleh dengan optimasi Nadam tidak optimal sehingga nilai kesalahan yang dihasilkan juga relatif besar.



Gambar 9. Plotting Nilai Prediksi dan Nilai nyata Dengan Optimasi SGD, $epoch = 99$, $batch = 30$

Pada Gambar 9, terlihat bahwa terdapat kesenjangan yang cukup signifikan antara data hasil prediksi dengan data pengujian aktual, yang menunjukkan bahwa hasil prediksi menggunakan model Long Short Term Memory (LSTM) dengan optimasi SGD tidak sesuai dengan data aktual. Hal ini didukung pula dengan nilai akurasi RMSE yang melebihi 100 persen yang menunjukkan bahwa berdasarkan kriteria nilai RMSE, model LSTM dengan optimasi SGD termasuk dalam kriteria performa yang tidak akurat. Hasil plotting dengan optimasi SGD dianggap kurang akurat dibandingkan optimasi Adam. RMSE yang diperoleh dengan optimasi SGD tidak optimal sehingga nilai kesalahan yang dihasilkan juga relatif besar.



Gambar 10. Plotting Nilai Prediksi dan Nilai nyata Dengan Optimasi Adagrad, *epoch* = 99, *batch* = 30

Pada Gambar 10, terlihat kesenjangan yang mencolok antara data prediksi dengan data pengujian aktual, yang mengindikasikan bahwa hasil prediksi menggunakan model Long Short Term Memory (LSTM) dengan optimasi Adagrad tidak selaras dengan data aktual. Kesimpulan ini didukung oleh nilai akurasi RMSE yang melebihi 100 persen. Berdasarkan kriteria nilai RMSE, dapat disimpulkan bahwa model LSTM dengan optimasi Adagrad termasuk dalam kriteria performa yang tidak akurat. Hasil plotting dengan optimasi Adagrad dianggap kurang akurat dibandingkan optimasi Adam. RMSE yang diperoleh dengan optimasi Adagrad tidak optimal sehingga nilai kesalahan yang dihasilkan juga relatif besar.



Gambar 11. Plotting Nilai Prediksi dan Nilai nyata Dengan Optimasi Adamax, *epoch* = 99, *batch* = 30

Pada gambar 11 bahwa terdapat perbedaan yang signifikan antara data pengujian (aktual) dan data prediksi. Hal ini menunjukkan bahwa hasil prediksi yang diperoleh dari model Long Short Term Memory dengan optimasi Adamax tidak jauh berbeda dengan data aktual. Hal ini didukung dengan nilai akurasi RMSE yang lebih dari 100% sehingga dapat disimpulkan bahwa model Long Short Term Memory dengan optimasi Adamax memiliki kriteria yang salah berdasarkan kriteria nilai RMSE. Hasil plotting dengan optimasi Adamax dianggap kurang akurat dibandingkan optimasi Adam. RMSE yang diperoleh dengan optimasi Adamax tidak optimal sehingga nilai kesalahan yang dihasilkan juga relatif besar.



Gambar 12. Plotting Nilai Prediksi dan Nilai nyata Dengan Optimasi Adadelata *epoch* = 99, *batch* = 30

Pada gambar 12, terdapat perbedaan yang cukup signifikan antara data prediksi dan data testing (aktual). Hal ini mengindikasikan bahwa hasil prediksi yang diperoleh dengan menggunakan model Long Short Term Memory dengan optimasi Adadelata tidak mendekati, atau bahkan cukup jauh dari, nilai sebenarnya. Hal ini didukung dengan nilai akurasi RMSE yang lebih tinggi dari 100%, sehingga dapat disimpulkan bahwa model Long Short Term Memory dengan optimasi Adadelata memiliki kriteria yang salah berdasarkan kriteria nilai RMSE. Hasil plotting dengan optimasi Adadelata dianggap kurang akurat dibandingkan optimasi Adam. RMSE yang diperoleh dengan optimasi Adadelata tidak optimal sehingga nilai kesalahan yang dihasilkan juga relatif besar.



Gambar 13. Plotting Nilai Prediksi dan Nilai nyata Dengan Optimasi FTRL *epoch* = 99, *batch* = 30

Pada Gambar 13, terdapat perbedaan yang mencolok antara data prediksi dan data pengujian aktual, yang menunjukkan bahwa hasil prediksi menggunakan model Long Short Term Memory (LSTM) dengan optimasi FTRL tidak sesuai dengan nilai aktual. Selain itu, plotting prediksi tidak mengikuti pola plotting nilai aktual. Pengamatan ini didukung lebih lanjut oleh nilai akurasi RMSE yang melebihi 1.000 persen. Oleh karena itu, berdasarkan kriteria nilai RMSE dapat disimpulkan bahwa model LSTM dengan optimasi FTRL termasuk dalam kriteria performa yang tidak akurat. Hasil plotting dengan optimasi FTRL dianggap kurang akurat dibandingkan optimasi Adam. RMSE yang diperoleh dengan optimasi FTRL tidak optimal sehingga nilai kesalahan yang dihasilkan juga relatif besar.

KESIMPULAN

Model Prediksi Harga Beras Medium Kota Mojokerto dibangun dengan menggunakan LSTM dan variasi 7 (tujuh) algoritma optimasi dan menghasilkan beberapa kesimpulan sebagai berikut: 1) Algoritma optimasi Adam menghasilkan hasil akurasi yang paling tinggi dengan nilai RMSE sebesar 2,35 persen dan nilai prediksi mendekati nilai aktual. Pemodelan prediksi harga beras medium Kota Mojokerto menggunakan metode *Long Short Term Memory* dengan jenis optimasi adam, *epoch* = 100 dan ukuran *batch* = 30; 2) Algoritma optimasi Nadam menghasilkan nilai RMSE sebesar 20,66 persen dan nilai prediksi menjauhi nilai aktual. Pemodelan prediksi harga beras medium Kota Mojokerto tidak disarankan menggunakan optimasi Nadam; 3) Algoritma optimasi SGD menghasilkan nilai RMSE sebesar 141,16 persen dan nilai prediksi menjauhi nilai aktual. Pemodelan prediksi harga beras medium Kota Mojokerto tidak disarankan menggunakan optimasi SGD; 4) Algoritma optimasi Adagrad menghasilkan nilai RMSE sebesar 165,49 persen dan nilai prediksi menjauhi nilai aktual. Pemodelan prediksi harga beras medium Kota Mojokerto tidak disarankan menggunakan optimasi Adagrad; 5) Algoritma optimasi Adamax menghasilkan nilai RMSE sebesar 144,79 persen dan nilai prediksi menjauhi nilai aktual. Pemodelan prediksi harga beras medium Kota Mojokerto tidak disarankan menggunakan optimasi Adamax; 6) Algoritma optimasi Adadelata menghasilkan nilai RMSE sebesar 648,32 persen dan nilai prediksi menjauhi nilai aktual. Pemodelan prediksi harga beras medium Kota Mojokerto tidak disarankan menggunakan optimasi Adadelata; 7) Algoritma optimasi FTRL menghasilkan nilai RMSE sebesar 1.555,24 persen dan nilai prediksi menjauhi nilai aktual. Pemodelan prediksi harga beras medium Kota Mojokerto tidak disarankan menggunakan optimasi FTRL. Sehingga model yang digunakan optimizer adam memiliki kinerja yang lebih baik dengan nilai RMSE paling kecil.

Ucapan Terimakasih

Ucapan terima kasih kami sampaikan kepada Kepala dan staff LPM Universitas Bina Sehat PPNI Mojokerto yang telah mendukung dalam penelitian kami yang menggunakan teknologi canggih untuk melakukan pemodelan prediksi harga beras medium di Kota Mojokerto.

DAFTAR REFERENSI

- Aldi, M. P., Jondri, & Aditsania, A. (2018). Analisis dan Implementasi Long Short Term Memory Neural Network untuk Prediksi Harga Bitcoin. e-Proceeding of Engineering.
- Adhitio Satyo Bayangkari Karno. (2020). ‘Analisa Data Time Series Menggunakan LSTM (Long Short Term Memory) dan ARIMA (Autocorrelation Integrated Moving Average) dalam Bahasa Python’, ULTIMA InfoSys, 11(1), pp 1-7
- Ali Khumaidi, Ridwan Raafi’udin, Indra Permana Solihin. (2020). ‘Pengujian Algoritma *Long Short Term Merory* untuk Prediksi Kualitas Udara dan Suhu Kota Bandung’, Jurnal Telematika Institut Teknologi Harapan Bangsa, 15(1), pp. 13-18
- Doni ANggara, Nana Suarna dan Yudhistira Arie Wijaya. (2023), ‘Analisa Perbandingan Performa Optimizer Adam, SGD dan RMSPROP pada Model H5’, Jurnal Ilmiah NERO, 8(1), pp. 53-64
- Hasibuan, L. H. and Musthofa, S. (2022) ‘Penerapan Metode Regresi Linear Sederhana Untuk Prediksi Harga Beras di Kota Padang’, JOSTECH: Journal of Science and Technology, 2(1): 85–95. doi:10.15548/jostech.v2i1.3802.
- Ba, J. L., & Kingma, D. P. (2015). Adam: A Method For Stochastic Optimization.
- Fauzin. (2021). “Pengaturan Impor Pangan Negara Indonesia Berbasis pada Kedaulatan Pangan”. Jurnal PAMATOR, 14(1), pp 1-9
- Jumina Cahyani, SYamsul Mujahidin dan Tegar PAlvus Fiqar. (2023), ‘Implementasi Metode Long Short Term Memory (LSTM) untuk Memprediksi Harga Bahan Pokok Nasional’, Jurnal Sistem dan Teknologi Informasi, 11(2), 346-357. DOI: 10.26418/justin.v11i2.57395.
- Khalis Sofi, Aswan Supriyadi Sunge and Antika Zahrotul Kamalia. (2021). ‘Perbandingan Algoritma Linear Regression, LSTM dan GRU Dalam Memprediksi Harga Saham Dengan Model Time Series’, Jurnal Universitas Mulia, pp.39-47. DOI: 10.47002/seminastika.v3i1.275
- Kusnadi, N. A. (2018) ‘Pengaruh fluktuasi kharga komoditas pangan terhadap inflasi di Provinsi Jawa Timur’, Jurnal Ilmiah Mahasiswa FEB Universitas Brawijaya, 6(2), pp. 1–19. Available at: <https://jimfeb.ub.ac.id/index.php/jimfeb/article/view/5128/4504>.
- Naim Rochmawati, Hanik Badriyah dan Yuni Yamasari. (2021), ‘Analisa Learning Rate dan Batch Size Pada Klasifikasi Covid Menggunakan Deep Learning dengan Optimizer Adam’, JIEET, 5(2), pp 44-48
- Putri Hariyanti, Nelvia Iryani and Putri Ayu (2023) ‘Fluktuasi Harga Komoditas Pangan Dan Pengaruhnya Terhadap Inflasi di Sumatera Barat’, Jurnal Ekuilnomi, 5(1), pp. 99–108. doi:10.36985/ekuilnomi.v5i1.554.
- Qiu, J., Wang, B., & Zhou, C. (2020). Forecasting Stock Prices with Long-Short Term Memory Neural Network Based on Attention Mechanism. PLOS ONE 15(1): e0227222, 2–3. <https://journals.plos.org/plosone/article/file?id=10.1371/journal.pone.0227222>.
- Suseno dan Astiyah, Siti (2009), ‘Inflasi’, Buku Seri Kebanksentralan PPSKBI
- Neelabh Pant, Sept 7, 2017. “A Guide For Time Series Prediction Using Recurrent Neural Networks (LSTMs)”, <https://blog.statsbot.co/time-series-prediction-using-recurrentneural-networks-lstms-807fa6ca7f>.